

Rapport de Projet : Traitement de Données

Analyse Statistique et Modélisation des Tirs au But

Titouan Rémi Mouaid

Juin 2026

Table des matières

1	Business goal	2
2	Team management	3
3	Data Visualisation	4
4	Handcrafted features	6
4.1	Quelles sont nos caractéristiques créées et comment ont-elles été dérivées ?	6
4.2	Comment vérifions-nous leur pertinence ?	7
5	Modélisation par Régression Logistique	7
5.1	La prévention des fuites de données	7
5.2	La gestion du déséquilibre des classes	7
5.3	Sélection des variables et du modèle	7
5.4	Évaluation : pourquoi l'AUC plutôt que la précision	7
5.5	Portée et limites du modèle	8
6	Conclusion	9
7	List of references	10

1 Business goal

Dans le monde du football professionnel, et plus particulièrement lors des compétitions à élimination directe comme la Coupe du Monde, la séance de tirs au but est souvent qualifiée de « loterie », comme l’a dit Didier Deschamps en 2022 après la défaite de l’équipe de France contre l’Argentine. Cette perception laisse entendre que l’issue de cet exercice reposerait sur le hasard ou la chance. Or, l’analyse de ce jeu de données permet de déconstruire ce mythe : le tir au but n’est pas un lancer de dés, c’est un geste technique très difficile, exécuté sous une contrainte psychologique, qui répond à des probabilités mathématiques modélisables.

L’objectif de cette étude est de transformer une base de données historique en un outil d’aide à la décision tactique pour un staff technique. À très haut niveau, chaque erreur peut avoir un impact pour la suite de la séance. S’en remettre uniquement à l’intuition de l’entraîneur ou au volontariat des joueurs est dangereux. Notre approche par différentes données vise à fournir un cadre rationnel pour optimiser trois paramètres fondamentaux :

- **A. L’optimisation de l’ordre de passage et la gestion de la pression :** Les fans de football débattent souvent sur la place du meilleur tireur de l’équipe : faut-il le mettre en premier pour rassurer, ou en cinquième pour conclure ? Notre modèle apporte une réponse empirique en quantifiant l’effet de la « Mort Subite ». Sachant que le taux de réussite s’effondre mathématiquement à partir du 6ème tireur en raison de la pression (chaque tir devenant potentiellement éliminatoire), l’outil permet au coach de structurer sa liste pour gagner la séance le plus tôt possible.
- **B. Le profil des tireurs :** Notre modèle met en évidence l’influence significative du poste (attaquant, milieu, défenseur) et de la latéralité (gaucher, droitier) sur la réussite du tir. Il établit notamment que la perte de précision est statistiquement plus prononcée chez un défenseur que chez un attaquant.
- **C. La rentabilité des zones de tir :** L’analyse des zones de tir exactes permet de d’enlever certaines idées reçues. Bien qu’un tir en pleine lucarne soit normalement imparable pour le gardien, nos données intègrent le paramètre du « hors-cadre ». On verra donc dans la suite que les tirs en hauteurs apportent plus de risques concernant la précision mais sont imparables si ils sont cadrés. Contrairement aux tirs du milieu et du bas qui eux assurent une précision mais sont plus faciles à arrêter si le gardien plonge du bon côté.

2 Team management

Jour 1

En nous inspirant de la finale de la Ligue des champions, nous avons choisi un dataset sur les tirs au but. Il contenait initialement 10 colonnes et 320 lignes. Nous avons également trouvé 4 notebooks, dont un correspond à notre vision et au type d'analyse que nous souhaitons réaliser. C'était notre premier contact avec Kaggle, et nous avons installé la bibliothèque Pandas.

En outre, nous avons effectué une phase de prétraitement des données : nous avons ajouté une colonne indiquant le poste du joueur et supprimé les lignes contenant des informations inutiles ou non exploitables pour notre analyse. À l'issue de ce nettoyage, nous avons obtenu un jeu de données de travail composé de 10 colonnes et 279 lignes.

Jour 2

Le matin : nous avons choisi le modèle de notre présentation et nous avons réalisé de nombreux graphiques (*plots*) à partir de nos données, en analysant deux dimensions ou plus à la fois afin de mieux comprendre le dataset. Nous avons commencé à sélectionner les visualisations les plus pertinentes pour les intégrer à la présentation et au rapport.

L'après-midi : nous avons réalisé davantage de graphiques pour approfondir notre analyse des données. Nous avons ensuite commencé à utiliser une régression logistique et obtenu des résultats avec une précision comprise entre 60 % et 70 %.

Jour 3

Nous avons poursuivi l'exploration des données en sélectionnant les graphiques les plus pertinents et en testant de nouvelles pistes d'analyse. Nous avons également approfondi notre compréhension de la régression logistique afin de mieux interpréter les résultats obtenus et améliorer le modèle malgré la baisse théorique des résultats prédits.

Enfin, nous avons commencé la rédaction du rapport et de la présentation, tout en réfléchissant à l'organisation du contenu dans chaque partie. À la fin de la séance, nous avons agrandi notre base de données en utilisant un autre dataset provenant de GitHub.

Jour 4

Nous avons adapté nos graphiques à notre jeu de données, qui est désormais plus grand. Nous avons également ajusté les variables construites manuellement (*handcrafted features*) afin d'améliorer nos analyses. Enfin, nous avons poursuivi la rédaction du rapport et peaufiné la présentation.

Jour 5

Nous avons présenté notre travail et, à partir des conseils et remarques du professeur, nous avons considérablement amélioré notre rapport.

3 Data Visualisation




FIGURE 1 – Taux de réussite selon la zone visée et la latéralité du tireur

Ce graphique met en évidence une différence nette selon la zone visée. Pour les droitiers, les tirs dirigés vers la droite du gardien présentent les meilleurs taux de réussite, souvent supérieurs à 75 %, tandis que les tirs au centre sont globalement les moins efficaces. Chez les gauchers, la tendance semble similaire avec de très bons résultats sur les tirs vers la droite, mais les effectifs étant plus faibles, ces résultats doivent être interprétés avec prudence. On observe également que les tirs dans les zones basses sont généralement moins efficaces que ceux placés en hauteur ou à mi-hauteur. Globalement, viser les côtés du but apparaît comme une stratégie plus performante que tirer au centre.




FIGURE 2 – Taux de réussite selon la hauteur du tir (tirs cadrés uniquement)

Ce graphique montre que lorsqu'un penalty est cadré, il a de très fortes chances d'être marqué s'il est tiré dans la partie haute du but. Les taux de réussite y sont presque systématiquement supérieurs à 90 %. Les gardiens parviennent rarement à arrêter ce type de tir, sauf lorsqu'il est placé près de leur position initiale. À l'inverse, les tirs bas sont plus souvent arrêtés, car ils sont plus accessibles lors d'un plongeon. La hauteur du tir semble donc être l'un des facteurs les plus importants pour maximiser les chances de marquer un penalty.




FIGURE 3 – Taux de réussite selon le contexte de pression (victoire, survie, neutre)

D'après ce graphique, le taux de réussite des tirs au but reste généralement compris entre 50 % et 80 % lorsqu'il n'y a pas d'enjeu particulier. En revanche, lorsque le tir peut directement apporter la victoire à l'équipe, le pourcentage de réussite augmente nettement. À l'inverse, lorsqu'il s'agit d'un tir de survie, le taux de réussite diminue fortement. Ces résultats suggèrent que la pression psychologique n'a pas le même effet selon le contexte.




FIGURE 4 – Visualisation multidimensionnelle : taux de réussite par poste, rang et pied fort

Ce graphique met en évidence l'influence du rang du penalty, de l'enjeu du tir et du poste du joueur sur le taux de réussite. La taille des bulles est proportionnelle au nombre d'observations disponibles. On observe que, dans les situations normales, les taux de réussite restent globalement proches de la moyenne de 68.3 % . En revanche, lorsque le tir est décisif pour gagner ou éviter l'élimination, les performances deviennent beaucoup plus variables. Les taux de réussite associés à une victoire potentielle sont généralement élevés, tandis que les situations de survie semblent davantage affectées par la pression. Toutefois, les effectifs étant plus faibles dans ces situations particulières, les résultats extrêmes doivent être interprétés avec prudence.

4 Handcrafted features

Dans leur format brut, les données collectées ne sont pas toujours optimales pour l'apprentissage d'un modèle algorithmique. L'ingénierie des caractéristiques a donc consisté à transformer ou combiner certaines variables explicatives afin d'en extraire un signal statistique plus fort et d'éviter le sur-apprentissage (*overfitting*) lié à notre échantillon de taille modeste (603 observations).




FIGURE 5 – Taux de réussite selon l'avancée, la situation au score et le poste du tireur

Ce graphique visualise trois features construites manuellement : la situation au score (couleur), le poste du tireur (forme) et le volume de tirs (taille des symboles). On observe que la situation au score est la variable la plus discriminante les joueurs menés voient leur taux chuter au fil de la séance, tandis que ceux en avance progressent légèrement. Le poste du tireur introduit une différence plus modeste, les attaquants restant légèrement plus efficaces. Ces tendances justifient l'intégration de ces variables comme features pertinentes pour le modèle.

4.1 Quelles sont nos caractéristiques créées et comment ont-elles été dérivées ?

Nous avons principalement conçu deux nouvelles caractéristiques métiers, complétées par une transformation mathématique des données catégorielles :

- **La variable de pression psychologique (Mort_Subite) :**

Dérivation : Nous avons transformé la variable ordinaire `Penalty_Number` en une variable binaire. Mathématiquement, si le rang du tir est supérieur ou égal à 11 (ce qui correspond au 6ème tireur d'une équipe et marque le début de la mort subite), la variable `Mort_Subite` prend la valeur 1. Sinon, elle vaut 0.

Justification : L'impact du rang de passage n'est pas linéaire. La différence de pression entre le 1er et le 2ème tir n'est pas la même qu'entre le 10ème et le 11ème. Binariser cette variable permet à l'algorithme d'isoler le point de bascule psychologique.

- **La hauteur :**

Dérivation : Dans notre jeu de données, la variable initiale de zone découpait le but en 9 sous-zones distinctes (1 à 9). Nous avons regroupé les zones du bas (7, 8, 9), du milieu (4, 5, 6) et celles du haut (1, 2, 3) pour créer une variable binaire ou catégorielle robuste.

- **Le moment du tir :**

Dérivation : Le fait de tirer en premier ou en deuxième a un impact psychologique sur le tir. Tirer en deuxième accentue la responsabilité et augmente fortement la pression sur le joueur, ce qui influe sur l'issue du tir surtout si le joueur précédent a marqué son tir au but.

- **Score state :**

Dérivation : Le score courant est une variable également très significative, probablement

davantage que la précédente, car elle joue beaucoup sur la psychologie du joueur.

4.2 Comment vérifions-nous leur pertinence ?

La validation de la pertinence de ces variables *handcrafted* a été réalisée via une étape :

1. **Data Visualisation** : Avant la modélisation, l'analyse graphique a permis de modifier certaines idées reçues. Nos visualisations ont démontré que la baisse apparente du taux de réussite en fin de séance n'est pas corrélée au numéro du tir de manière chronologique, mais plutôt liée à l'enjeu psychologique du tireur. Le taux chute très souvent quand le tireur porte sur lui le poids d'une potentielle élimination de son équipe. Cependant, on a vu que quand il a le penalty de la victoire entre les mains, il a bien moins de risque de le louper car dans le pire des cas, si il loupe, la séance se poursuivra.

5 Modélisation par Régression Logistique

5.1 La prévention des fuites de données

Le choix le plus déterminant de notre modélisation n'a pas été d'ajouter des variables, mais d'en retirer. Deux variables disponibles dans le jeu de données auraient artificiellement gonflé nos performances : la direction du plongeon du gardien et le fait que le tir soit cadré .

Ces deux informations constituent en effet des fuites de données : elles ne sont connues qu'au moment même de la frappe, et non avant. Or notre objectif est de prédire l'issue d'un tir à partir d'informations disponibles a priori. Le cas de OnTarget est le plus parlant : un tir non cadré est mécaniquement un échec, si bien que cette variable équivaut presque à la réponse elle-même. L'inclure faisait bondir l'aire sous la courbe (AUC) à environ 0,70, mais ce score n'avait aucune valeur prédictive réelle. Nous avons donc exclu ces variables et restreint notre étude aux tirs cadrés uniquement, seul périmètre sur lequel la question « le tireur va-t-il marquer ? » a un sens statistique.

5.2 La gestion du déséquilibre des classes

Notre variable cible est fortement déséquilibrée : environ 77 % des tirs cadrés se transforment en but. Un modèle naïf maximiserait sa précision en prédisant systématiquement « but », sans rien apprendre. Pour l'en empêcher, nous avons utilisé le paramètre `class_weight='balanced'`, qui pondère chaque classe inversement à sa fréquence : une erreur sur un arrêt (classe rare) coûte ainsi environ trois fois plus cher qu'une erreur sur un but. Le modèle est donc contraint d'apprendre réellement à identifier les arrêts, au lieu de se réfugier dans la classe majoritaire.

5.3 Sélection des variables et du modèle

Nous avons comparé plusieurs jeux de variables et plusieurs algorithmes par validation croisée. Deux enseignements en ressortent :

D'une part, remplacer la zone brute à neuf modalités par notre variable `Tir_haut` (binaire : tir visé en hauteur ou non) améliore le modèle. Le découpage fin en neuf cases dispersait l'information sur des effectifs trop faibles et n'apportait que du bruit ; l'information utile de placement se résume essentiellement à la hauteur du tir.

5.4 Évaluation : pourquoi l'AUC plutôt que la précision

Compte tenu de la taille limitée de notre échantillon, nous n'avons pas évalué le modèle sur un seul découpage, mais par validation croisée à 5 plis (*5-fold cross-validation*), qui moyenne la performance sur cinq partitions différentes et fournit une estimation bien plus fiable.

Nous avons délibérément privilégié l’AUC (aire sous la courbe ROC) à la précision (*accuracy*). Sur des classes déséquilibrées, la précision est en effet trompeuse : prédire « but » en permanence donne déjà 77 % de bonnes réponses. L’AUC, elle, mesure la capacité du modèle à ordonner correctement les tirs : c’est la probabilité que, pour un but et un arrêt tirés au hasard, le modèle attribue un score plus élevé au but. Une valeur de 0,5 correspond au hasard, 1 à un classement parfait.

Notre meilleur modèle atteint une AUC d’environ 0,635, contre 0,621 pour le modèle de base sans variables handcrafted. La précision, autour de 0,53, est volontairement basse : c’est la contrepartie du rééquilibrage, qui rend le modèle attentif aux arrêts. La matrice de confusion confirme ce compromis : le modèle identifie correctement près de 70 % des arrêts (au prix de fausses alertes sur les buts), là où un modèle naïf n’en détecterait aucun.

5.5 Portée et limites du modèle

Nous tenons à présenter ces résultats avec honnêteté. Le gain apporté par nos variables handcrafted (+0,014 d’AUC) est présent mais modeste. De même, le fait d’avoir retenu le meilleur modèle parmi plusieurs combinaisons testées tend à optimiser légèrement le résultat ; une estimation prudente situe donc notre performance « autour de 0,63 ».

Ce n’est cependant pas un échec : c’est en lui-même un résultat. Une fois écartées les variables qui relèvent de la frappe elle-même (et notamment le choix du gardien), l’issue d’un penalty demeure en grande partie assez imprévisible. C’est précisément ce qui fait la tension de l’exercice. Notre modèle ne prétend donc pas deviner chaque tir, mais il dégage les leviers statistiquement valides — viser haut, et tenir compte du contexte de pression — ce qui répond à notre problématique de départ et à nos objectifs que l’on s’était fixé. Notre meilleur modèle atteint une AUC d’environ 0,635, contre 0,621 pour le modèle de base. La précision, autour de 0,53, est volontairement basse : c’est la contrepartie du rééquilibrage, qui rend le modèle attentif aux arrêts. La matrice de confusion (figure 6) confirme ce compromis : le modèle identifie correctement près de 70 % des arrêts (au prix de fausses alertes sur les buts), là où un modèle naïf n’en détecterait aucun.




FIGURE 6 – **Matrice de confusion du modèle (validation croisée)**. Les lignes correspondent à la réalité, les colonnes à la prédiction du modèle.

6 Conclusion

L'objectif de ce projet était de comprendre si l'exercice des penaltys au football est un simple coup de chance, ou s'il peut être modélisé via un véritable modèle mathématique grâce à différentes variables telles que : l'impact technique, le profil des joueurs et, surtout, la pression psychologique.

À travers une démarche analytique articulée autour de la Data Visualisation, puis validée par un modèle de régression logistique, nous avons pu trouver des réponses intéressantes à notre questionnement de base. Le principal enseignement de notre étude est que la probabilité de réussite d'un penalty n'est pas corrélée chronologiquement au numéro du tir, mais à son enjeu psychologique immédiat. La peur de l'élimination, lorsqu'un joueur tire pour ne pas perdre, le paralyse et le pousse à rater plus souvent sa tentative. Au contraire, si le joueur tire pour faire gagner son équipe, l'enjeu agit comme un stimulant et le taux de réussite est bien plus élevé à ce moment-là.

Cependant, notre démarche possède des limites qu'il convient de souligner. En effet, même si nos variables *handcrafted* ont prouvé qu'elles pouvaient apporter une véritable réponse statistique, un modèle ne peut pas capturer l'intégralité du contexte d'un match. Il existe des facteurs cruciaux tels que la fatigue physique après 120 minutes d'effort, l'historique psychologique entre un tireur et un gardien, ou même le scénario du match qui a pu donner l'ascendant psychologique à une équipe.

Notre analyse n'est donc pas parfaite et pourrait être améliorée. L'intégration à notre étude de données de *tracking* vidéo — mesurant par exemple la vitesse de la course d'élan ou l'angle du regard du joueur (s'il fixe la zone visée ou le ballon) — constituerait une très belle perspective d'amélioration pour de futures analyses.

En fin de compte, même si l'analyse de données et les mathématiques nous permettent d'optimiser les décisions tactiques et de maximiser les probabilités de victoire, elles nous rappellent aussi une vérité essentielle. Un événement inattendu, comme la glissade d'un joueur ou l'intuition d'un gardien, peut toujours survenir. C'est cela qui fait la beauté de ce sport. Rien n'est prévisible à 100 %, sinon on s'ennuierait et il n'y aurait plus aucun intérêt à regarder du football.

7 List of references

- **Sources des données :**
 - [Kaggle : World Cup Penalty Shootouts](#) (Pablo L. Landeros)
 - [GitHub : StatsBomb Open Data](#)
- **Supports de cours MAM3 :**
 - [Lecture 1 : Introduction](#) (L. Fillatre)
 - [Lecture 2 : Handling Data](#) (L. Fillatre)
 - [Lecture 3 : Data Visualisation and Data Exploration](#) (L. Fillatre)
 - [Lecture 4 : Introduction to Modelling](#) (L. Fillatre)
- **Outils informatiques (Bibliothèque Scikit-Learn) :**
 - [Documentation de l'API : Implémentation de la Régression Logistique](#)
- **GitHub de suivi :**
 - [Lien GitHub](#) avec tous nos graphes, les codes et les idées de départ